Machine Learning e Data Mining

anno accademico 2026/2027

Ambra Demontis, Fabio Brau

Pattern Recognition and Applications Lab
Department of Electrical and Electronic Engineering
University of Cagliari (Italy)



Regressione lineare

Outline

Il problema della regressione

Nozioni minime di probabilità e statistica

Il modello della regressione lineare

Stima dei parametri: massima verosimiglianza

Analisi dei residui

1. Il problema della regressione

Che cos'è la regressione?

Idea

Vogliamo prevedere una quantità numerica continua a partire da alcune caratteristiche osservate.

Esempi:

- prevedere il prezzo di un appartamento da metratura, piano, zona;
- prevedere il consumo elettrico di domani da temperatura e giorno della settimana;
- stimare l'età di una persona da una fotografia;

dati e obiettivo

- Un esempio (campione) è descritto da D caratteristiche (feature):
$$\boldsymbol{x} = [x_1, x_2, \ldots, x_D]^\top \in \mathbb{R}^D$$
- A ogni esempio è associato un valore da prevedere (target, etichetta):
$$y \in \mathbb{R}$$
- Abbiamo a disposizione un insieme di addestramento di N esempi:
$$\mathcal{D} = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_N, y_N)\}$$

Obiettivo

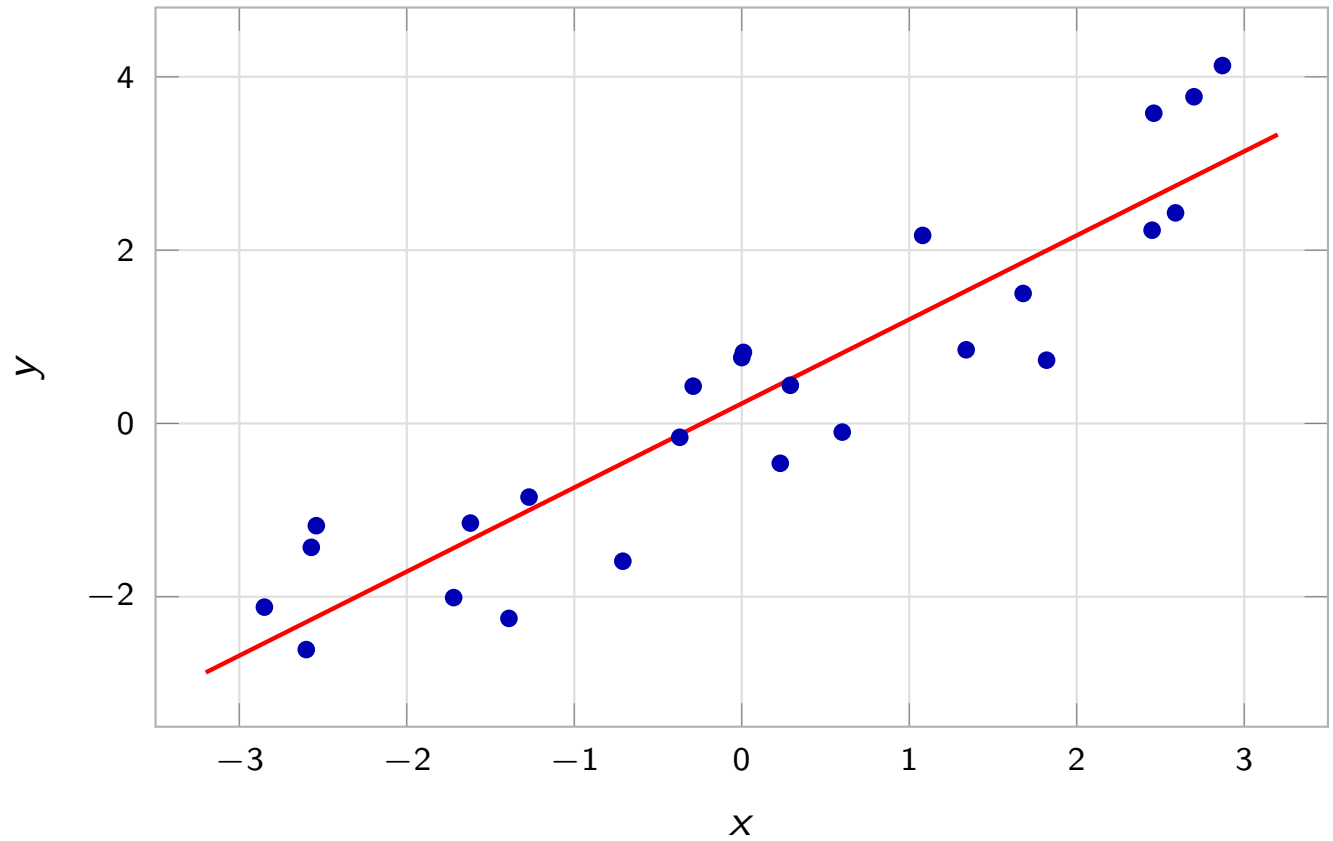
Trovare una funzione $f : \mathbb{R}^D \to \mathbb{R}$ tale che $f(\boldsymbol{x}) \approx y$ anche per esempi nuovi, mai visti durante l'addestramento.

Esempio concreto ($D = 3$, $N = 5$)

$\boldsymbol{x}$ (feature)			y (target)
mq	piano	età edificio	prezzo (k euro)
60	1	30	145
85	3	5	260
120	2	45	230
45	0	60	95
100	4	10	295

- Ogni riga è un esempio $(\boldsymbol{x}_n, y_n)$.
- Ogni colonna di sinistra è una feature.
- Vogliamo una funzione che, data una nuova casa, stimi il prezzo.

Il caso più semplice: $D = 1$



- I punti sono i dati osservati, la retta è il modello.
- Tipicamente nessuna retta passa per tutti i punti: i dati sono rumorosi.

Perché i dati non stanno su una retta perfetta?

Rumore

Tutto ciò che influenza y ma che non abbiamo misurato o non possiamo prevedere.

Cause tipiche:

- errori di misura (sensori, arrotondamenti, errori di trascrizione);
- variabili mancanti: il prezzo dipende anche dalla vista, dal vicino rumoroso, dalla fretta del venditore;
- variabilità intrinseca del fenomeno;
- il nostro modello è comunque una semplificazione della realtà.

Conseguenza

Un modello che riproduce *esattamente* i dati di addestramento sta imparando anche il rumore: generalizzerà male. Il rumore va modellato, non inseguito.

2. Nozioni minime di probabilità e statistica

Eventi e probabilità

- Esperimento aleatorio: un esperimento il cui esito non è noto in anticipo
- Spazio campionario Ω: l'insieme di tutti i possibili esiti.
- Evento $A \subseteq \Omega$: un sottoinsieme di esiti.

Probabilità

Dato un evento A, $P(A)$ misura il grado di convinzione che l'evento si verifichi.

Proprietà fondamentali:

- $0 \leq P(A) \leq 1 \quad$ e $\quad P(\Omega) = 1$;

Variabile aleatoria

Definizione informale

Una variabile aleatoria è una quantità il cui valore non è noto in anticipo: dipende dall'esito di un esperimento.

- Discreta: il numero di possibili valori è finito o numerabile infinito.
- Continua: il numero di possibili valori non è finito o numerabile infinito.
  Es.: assume valori in un intervallo di $\mathbb{R}$.

Attenzione

Per una variabile continua Y, $P(Y = 2.000\ldots) = 0$: ha senso solo chiedersi la probabilità di un intervallo, ad es. $P(1.9 \leq Y \leq 2.1)$.

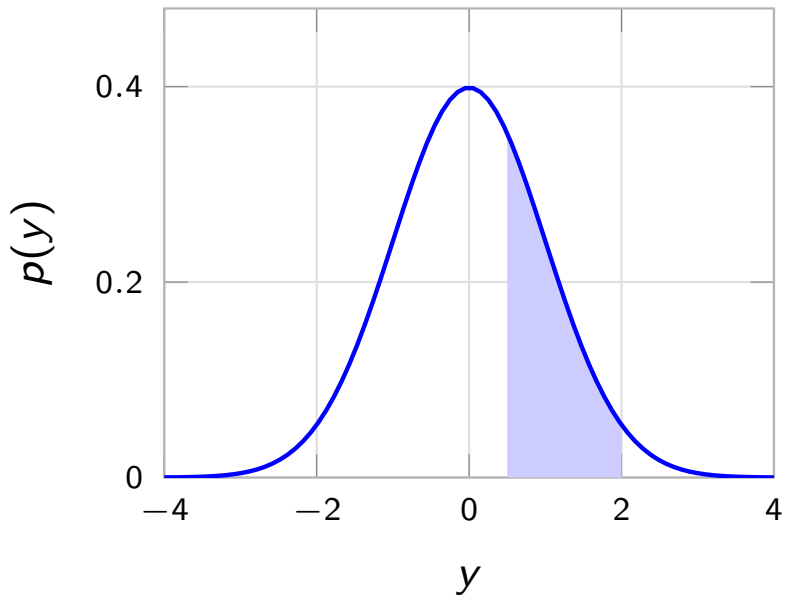
Densità di probabilità

Una variabile continua Y è descritta da una densità $p(y) \geq 0$:

$$P(a \leq Y \leq b) = \int_a^b p(y)\, dy$$

$$\int_{-\infty}^{+\infty} p(y)\, dy = 1$$

- la probabilità è un'area;
- dove $p(y)$ è alta, i valori sono più plausibili;



L'area colorata è $P(0.5 \leq Y \leq 2)$.

Media (valore atteso) e varianza

Valore atteso

$$\mu = \mathbb{E}[Y]$$

È il "centro di massa" della distribuzione: il valore medio che otterremmo ripetendo l'esperimento infinite volte.

Varianza e deviazione standard

$$\sigma^2 = \mathrm{Var}[Y] = \mathbb{E}\big[(Y-\mu)^2\big], \qquad \sigma = \sqrt{\sigma^2}$$

Misurano quanto i valori si disperdono attorno alla media. σ ha la stessa unità di misura di Y.

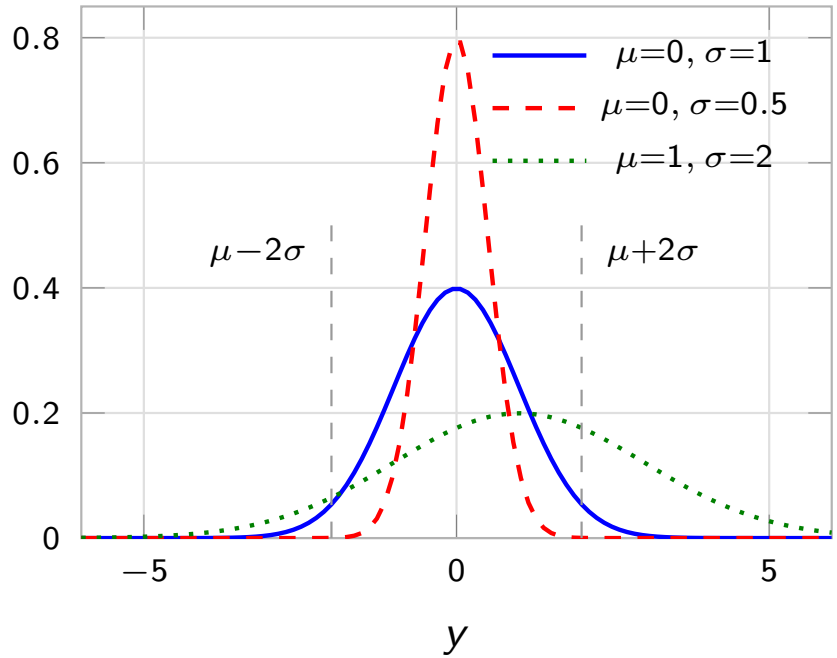
Stime a partire da N dati osservati: $\hat{\mu} = \frac{1}{N}\sum_{n=1}^{N} y_n$, $\hat{\sigma}^2 = \frac{1}{N}\sum_{n=1}^{N}(y_n - \hat{\mu})^2$.

La distribuzione gaussiana (o normale)

$$p(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right)$$

Si scrive $Y \sim \mathcal{N}(\mu, \sigma^2)$.

- simmetrica attorno a μ;
- μ sposta la campana, σ la allarga;
- decresce molto rapidamente: valori lontani da μ sono molto improbabili.



Le linee tratteggiate sono $\mu \pm 2\sigma$ per la curva blu.

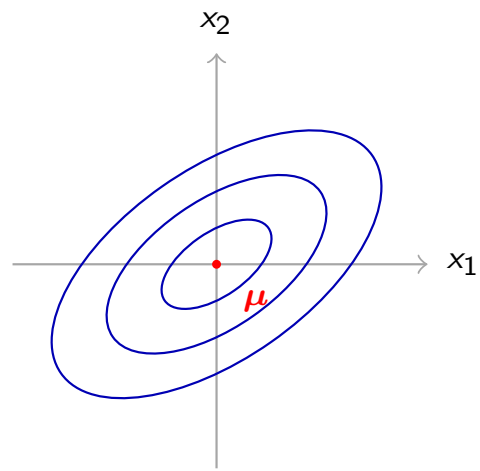
Circa il 95% dei valori cade in $\mu \pm 2\sigma$.

La gaussiana multivariata

Se $\boldsymbol{y} \in \mathbb{R}^D$ è un vettore di variabili aleatorie, $\boldsymbol{y} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$:

$$p(\boldsymbol{y}) = \frac{1}{(2\pi)^{D/2}\,|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\tfrac{1}{2}(\boldsymbol{y}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{y}-\boldsymbol{\mu})\right)$$

- $\boldsymbol{\mu} \in \mathbb{R}^D$: vettore delle medie;
- $\boldsymbol{\Sigma} \in \mathbb{R}^{D\times D}$: matrice di covarianza, simmetrica, con $\Sigma_{ij} = \mathbb{E}[(y_i - \mu_i)(y_j - \mu_j)]$;
- $\Sigma_{ii} = \mathrm{Var}[y_i]$, mentre Σ_{ij} con $i \neq j$ dice se y_i e y_j variano insieme.
- Stima a partire da n dati osservati: $\frac{1}{N}\sum_{n=1}^{N}\left((\boldsymbol{y}_n - \boldsymbol{\mu})(\boldsymbol{y}_n - \boldsymbol{\mu})^\top\right)$



Curve di livello: ellissi centrate in $\boldsymbol{\mu}$.

3. Il modello della regressione lineare

L'obiettivo della regressione

Disponiamo di N coppie di addestramento

$$\mathcal{D} = \{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)\}, \qquad \boldsymbol{x}_n \in \mathbb{R}^D, \quad y_n \in \mathbb{R}$$

$$y_n = f(\boldsymbol{x}_n) + \varepsilon, \qquad n = 1, \ldots, N$$

dove ε è una variabile aleatorie che rappresenta il rumore.

Obiettivo

Inferire dall'intero dataset la funzione f che ha generato le osservazioni che generalizza bene su nuovi input, mai visti in addestramento.

- f è ignota: dovremo sceglierne una famiglia e stimarne i parametri.

La regressione lineare

Scegliamo la famiglia di funzioni più semplice, le funzioni lineari nei parametri:

$$\boxed{f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{\theta}} \qquad \boldsymbol{\theta} \in \mathbb{R}^D$$

dove

$$\boldsymbol{x}^\top \boldsymbol{\theta} = x_1\theta_1 + x_2\theta_2 + \cdots + x_D\theta_D = \sum_{d=1}^{D} x_d\theta_d$$

- $\boldsymbol{\theta}$ sono i parametri (detti anche pesi, coefficienti) da stimare dai dati: scegliere f si riduce a scegliere D numeri;
- θ_d dice quanto pesa la feature d nella predizione;
- la predizione del modello è $\hat{y} = \boldsymbol{x}^\top \boldsymbol{\theta}$: una retta per $D = 1$, un piano per $D = 2$, un iperpiano in generale.

Il termine costante (intercetta / bias)

Il modello $y = \boldsymbol{x}^\top \boldsymbol{\theta}$ con $D = 1$ è $y = \theta_1 x$: una retta che passa obbligatoriamente per l'origine. Troppo restrittivo.

Trucco standard

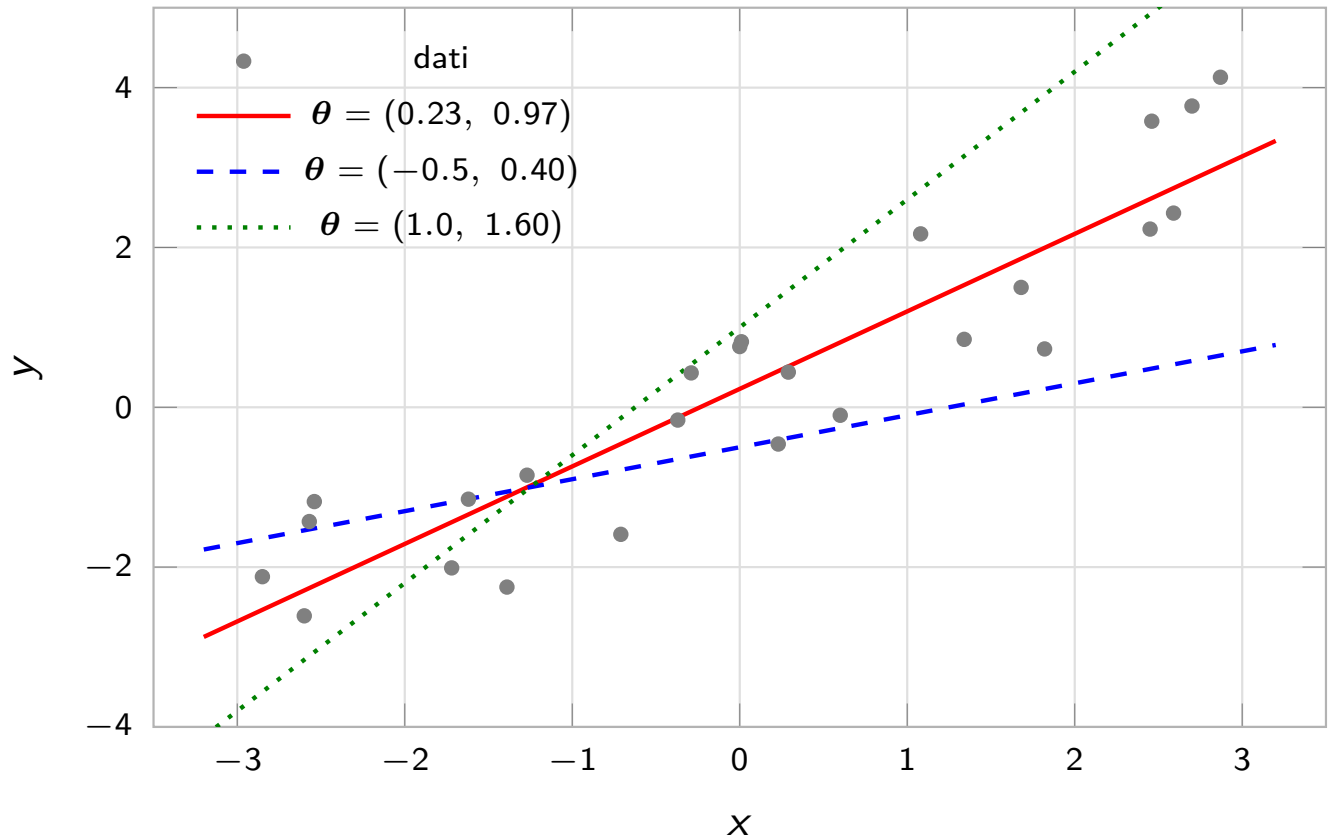
Si aggiunge una feature costante uguale a 1:

$$\tilde{\boldsymbol{x}} = \begin{bmatrix} 1 \\ \boldsymbol{x} \end{bmatrix} \in \mathbb{R}^{D+1}, \qquad \tilde{\boldsymbol{\theta}} = \begin{bmatrix} \theta_0 \\ \boldsymbol{\theta} \end{bmatrix} \in \mathbb{R}^{D+1}$$

$$\tilde{\boldsymbol{x}}^\top \tilde{\boldsymbol{\theta}} = \theta_0 + x_1\theta_1 + \cdots + x_D\theta_D$$

- θ_0 è l'intercetta: il valore previsto quando tutte le feature sono nulle.
- Tutta la teoria resta identica: cambia solo la dimensione del vettore.
- Nel seguito supponiamo che la colonna di 1 sia già inclusa in $\boldsymbol{x}$.

Parametri diversi, rette diverse ($D = 2$ con bias)



- Ogni scelta di $\boldsymbol{\theta}$ è un'ipotesi sul fenomeno.
- Serve un criterio quantitativo per dire quale retta è la migliore.

Modelliamo il rumore

Il modello lineare da solo non basta: per nessun $\boldsymbol{\theta}$ vale $y_n = \boldsymbol{x}_n^\top \boldsymbol{\theta}$ esattamente per tutti gli esempi. Aggiungiamo un termine di rumore e ne assumiamo la distribuzione:

$$y = \boldsymbol{x}^\top \boldsymbol{\theta} + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

- $\boldsymbol{x}^\top \boldsymbol{\theta}$: la parte sistematica, che possiamo prevedere;
- ε: il rumore, a media zero (non sbagliamo sistematicamente per eccesso o per difetto) e varianza σ^2 costante;

In termini di densità condizionata:

$$p(y \mid \boldsymbol{x}, \boldsymbol{\theta}) = \mathcal{N}(y \mid \boldsymbol{x}^\top \boldsymbol{\theta},\ \sigma^2)$$

Per ora consideriamo σ^2 nota.

4. Stima dei parametri: massima verosimiglianza

Il problema di stima

Dato il dataset di addestramento

$$\mathcal{D} = \{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)\}, \qquad \boldsymbol{x}_n \in \mathbb{R}^D, \; y_n \in \mathbb{R}$$

raccogliamo i dati in forma matriciale:

$$\boldsymbol{X} = \begin{bmatrix} \boldsymbol{x}_1^\top \\ \boldsymbol{x}_2^\top \\ \vdots \\ \boldsymbol{x}_N^\top \end{bmatrix} \in \mathbb{R}^{N \times D}, \qquad \boldsymbol{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} \in \mathbb{R}^N$$

- $\boldsymbol{X}$ è la matrice di design: una riga per esempio, una colonna per feature;
- $\boldsymbol{y}$ è il vettore dei target (le osservazioni).

Obiettivo: Massima Verosimiglianza

Trovare $\boldsymbol{\theta}$ che rende le osservazioni più plausibili possibile:

$$\boldsymbol{\theta}_{\mathrm{ML}} = \arg\max_{\boldsymbol{\theta}} \; p(\boldsymbol{y} \mid \boldsymbol{X}, \boldsymbol{\theta})$$

Passo 1: Teniamo conto dell'indipendenza

Per l'ipotesi i.i.d. (indipendenti e identicamente distribuiti) la verosimiglianza si fattorizza:

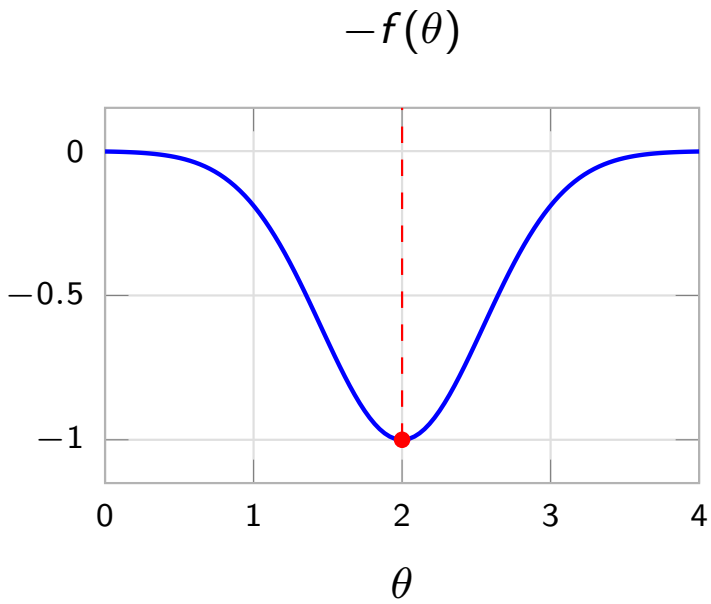
$$p(\boldsymbol{y} \mid \boldsymbol{X}, \boldsymbol{\theta}) = p(y_1, \dots y_N \mid \boldsymbol{x}_1, \dots \boldsymbol{x}_N, \boldsymbol{\theta}) = \prod_{n=1}^{N} p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta})$$

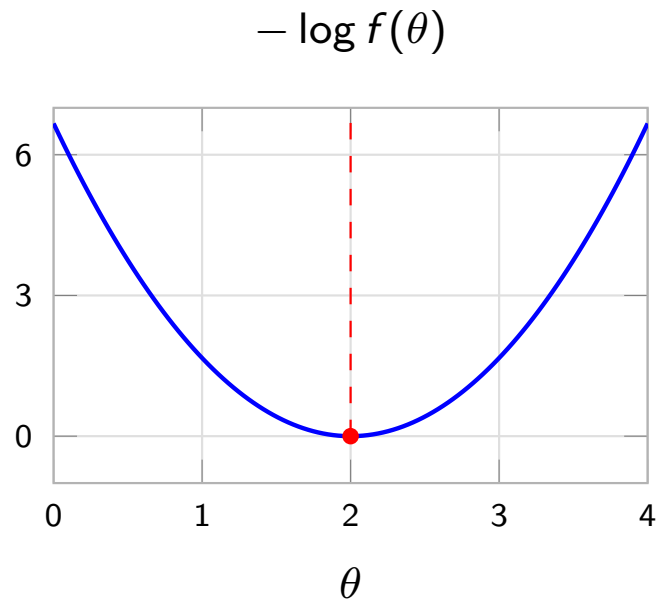
$$\boldsymbol{\theta}_{\mathrm{ML}} = \arg\max_{\boldsymbol{\theta}} \prod_{n=1}^{N} p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta})$$

Passo 2: Passiamo alla verosimiglianza logaritmica negativa

$$\boldsymbol{\theta}_{\mathrm{ML}} = \arg\min_{\boldsymbol{\theta}} -log \prod_{n=1}^{N} p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta})$$

Perché il logaritmo non sposta il minimo





- Il logaritmo è monotonicamente crescente: preserva l'ordinamento dei candidati
- Le due curve hanno forma e valori diversi, ma il minimo cade nello stesso θ.

Passo 3: scrivere $\mathcal{L}(\boldsymbol{\theta})$ esplicitamente

$$\boldsymbol{\theta}_{\mathrm{ML}} = \arg\min_{\boldsymbol{\theta}} \underbrace{-log \prod_{n=1}^{N} p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta})}_{\mathcal{L}}$$

Con $p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}) = \mathcal{N}(y_n \mid \boldsymbol{x}_n^\top \boldsymbol{\theta}, \sigma^2)$:

$$\boxed{\mathcal{L} = \frac{1}{2\sigma^2} \sum_{n=1}^{N} \left(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta}\right)^2 - \sum_{n=1}^{N} \log \frac{1}{\sqrt{2\pi\sigma^2}}}$$

Scartando i termini che non dipendono da $\boldsymbol{\theta}$:

$$\boldsymbol{\theta}_{\mathrm{ML}} = \arg\min_{\boldsymbol{\theta}} \frac{1}{2\sigma^2} \sum_{n=1}^{N} \left(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta}\right)^2 + \text{cost.}$$

Massima verosimiglianza = minimi quadrati

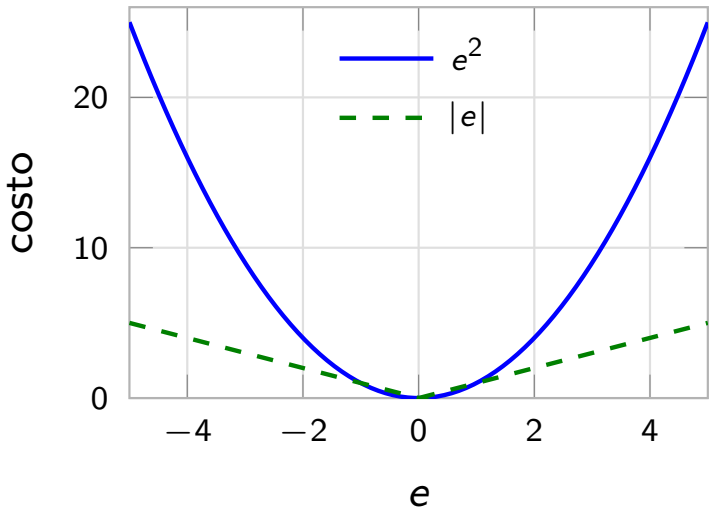
Sotto l'ipotesi di rumore gaussiano additivo, massimizzare la verosimiglianza è equivalente a minimizzare la somma degli scarti al quadrato:

$$\boldsymbol{\theta}_{\mathrm{ML}} = \arg\min_{\boldsymbol{\theta}} \frac{1}{2\sigma^2} \sum_{n=1}^{N} \left(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta}\right)^2 = \arg\min_{\boldsymbol{\theta}} \frac{1}{2\sigma^2} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\theta}\|^2$$

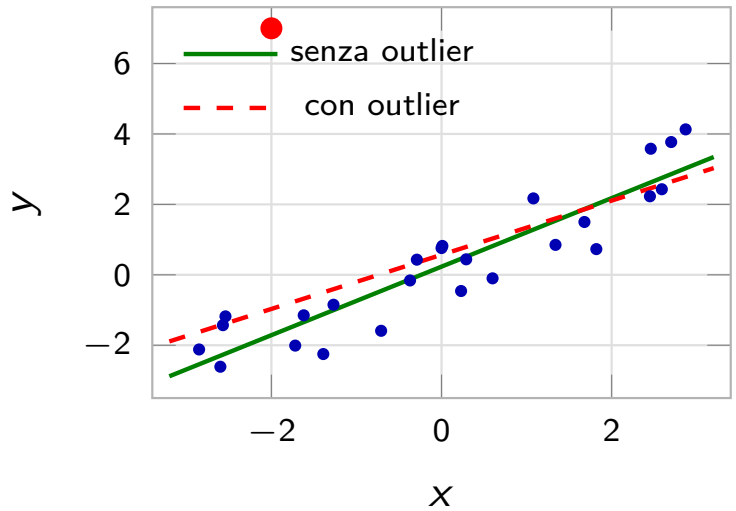
- L'errore quadratico non è una scelta arbitraria: deriva dall'ipotesi gaussiana.
- Questo spiega perché i minimi quadrati sono sensibili agli outlier: la gaussiana considera gli scarti grandi quasi impossibili, quindi li "punisce" molto.

Perché gli outlier pesano così tanto

costo di un singolo residuo



effetto sulla retta stimata



- Il costo cresce col quadrato: raddoppiare il residuo lo quadruplica. Un punto con residuo 10 pesa quanto 100 punti con residuo 1.
- Conviene quindi spostare la retta verso l'outlier, peggiorando tutti gli altri esempi, pur di ridurre quell'unico scarto enorme.
- La causa è l'ipotesi gaussiana: uno scarto di 5σ è ritenuto quasi impossibile, e il modello "preferisce" credere di aver sbagliato retta.

Passo 4: Verifichiamo che esiste un unico minimo globale

$$\sum_{n=1}^{N} \frac{1}{2\sigma^2}(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta})^2 = \frac{1}{2\sigma^2}\left(\boldsymbol{y}^\top \boldsymbol{y} - 2\,\boldsymbol{y}^\top \boldsymbol{X}\boldsymbol{\theta} + \boldsymbol{\theta}^\top \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{\theta}\right)$$

- È una quadratica in $\boldsymbol{\theta}$.
- Il termine quadratico ha matrice $\boldsymbol{X}^\top \boldsymbol{X}$, che, se $\boldsymbol{X}$ ha colonne linearmente indipendenti, è definita positiva
- Dunque L è strettamente convessa: è una "parabola" multidimensionale.
- Annullando il gradiente troviamo il minimo globale (se $\boldsymbol{X}$ ha colonne linearmente indipendenti.

Passo 5: calcolare il gradiente

Deriviamo rispetto a $\boldsymbol{\theta}$:

$$\nabla_{\theta} \frac{1}{2\sigma^2} \Big(\boldsymbol{y}^\top \boldsymbol{y} - 2\, \boldsymbol{y}^\top \boldsymbol{X} \boldsymbol{\theta} + \boldsymbol{\theta}^\top \boldsymbol{X}^\top \boldsymbol{X} \boldsymbol{\theta} \Big)$$

$$= \frac{1}{\sigma^2} \Big(- \boldsymbol{y}^\top \boldsymbol{X} + \boldsymbol{\theta}^\top \boldsymbol{X}^\top \boldsymbol{X} \Big)$$

Passo 6: annullare il gradiente

$$\frac{1}{\sigma^2}\Big(- \boldsymbol{y}^\top \boldsymbol{X} + \boldsymbol{\theta}^\top \boldsymbol{X}^\top \boldsymbol{X}\Big) = \mathbf{0}^T$$

Si ottengono le equazioni normali:

$$\boxed{\boldsymbol{X}^\top \boldsymbol{X}\, \boldsymbol{\theta} = \boldsymbol{X}^\top \boldsymbol{y}}$$

e se $\boldsymbol{X}^\top \boldsymbol{X}$ è invertibile:

$$\boxed{\boldsymbol{\theta}_{\mathrm{ML}} = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{y}}$$

Quando $\boldsymbol{X}^\top \boldsymbol{X}$ non è invertibile?

$\boldsymbol{X}^\top \boldsymbol{X} \in \mathbb{R}^{D \times D}$ è invertibile $\iff$ $\boldsymbol{X}$ ha rango pieno D, cioè le colonne (le feature) sono linearmente indipendenti.

Casi problematici:

- $N < D$: meno esempi che feature (es. 50 pazienti, 2000 geni);
- feature duplicate o ridondanti: "altezza in cm" e "altezza in m";
- collinearità: una feature è (quasi) combinazione lineare delle altre, ad es. "mq totali" = "mq zona giorno" + "mq zona notte";
- una feature costante oltre all'intercetta.

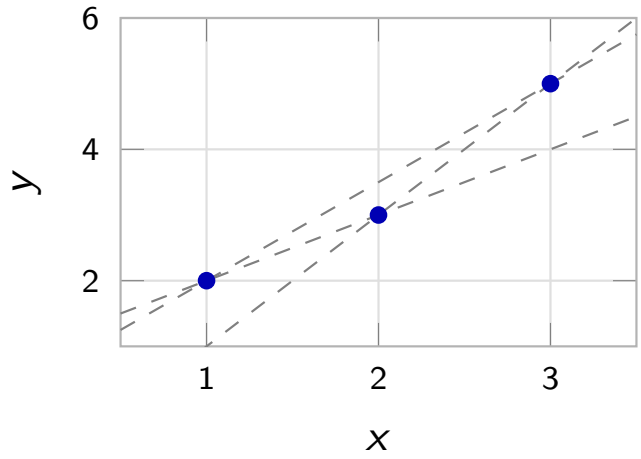
Rimedi (cenni)

- aumentare il numero di campioni di training
- eliminare/aggregare le feature ridondanti;
- aggiungere un termine di regolarizzazione:

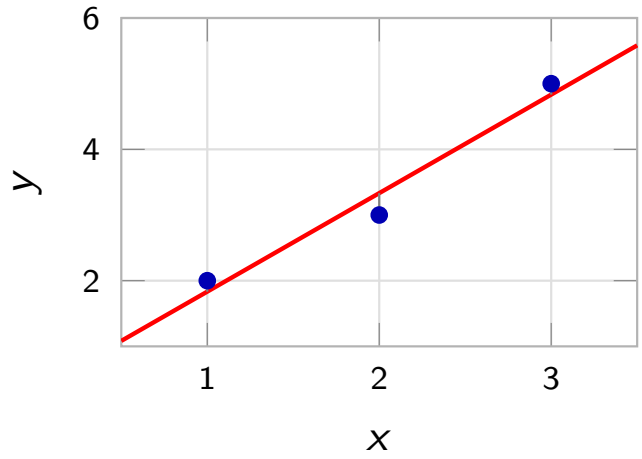
$\boldsymbol{X\theta} = \boldsymbol{y}$ oppure $\boldsymbol{X}^\top\boldsymbol{X\theta} = \boldsymbol{X}^\top\boldsymbol{y}$?

Esempio: $N = 3$ punti, $D = 2$ parametri (intercetta e pendenza).

$\boldsymbol{X\theta} = \boldsymbol{y}$: nessuna soluzione



$\boldsymbol{X}^\top\boldsymbol{X\theta} = \boldsymbol{X}^\top\boldsymbol{y}$: unica



- $\boldsymbol{X\theta} = \boldsymbol{y}$ sono N equazioni in D incognite: con $N > D$ è sovradeterminato e in generale incompatibile. Ogni retta tratteggiata soddisfa due equazioni su tre, nessuna tutte e tre.
- $\boldsymbol{X}^\top\boldsymbol{X\theta} = \boldsymbol{X}^\top\boldsymbol{y}$ è sempre compatibile, con soluzione unica se $\boldsymbol{X}$ ha rango pieno.
- Se $\boldsymbol{y} \in \mathrm{span}(\boldsymbol{X})$ i due sistemi coincidono e i residui sono nulli.

Aspetti computazionali

- Costo di $\boldsymbol{X}^\top \boldsymbol{X}$: $O(ND^2)$; inversione: $O(D^3)$.
- Non si invertono le matrici nel codice di produzione: si risolve il sistema lineare $\boldsymbol{X}^\top \boldsymbol{X}\,\boldsymbol{\theta} = \boldsymbol{X}^\top \boldsymbol{y}$
- Se i dati non stanno in memoria: si usa la discesa del gradiente (stochastic gradient descent) che è l'algoritmo iterativo standard per i modelli più complessi (reti neurali).

Valori predetti e residui

Definizione

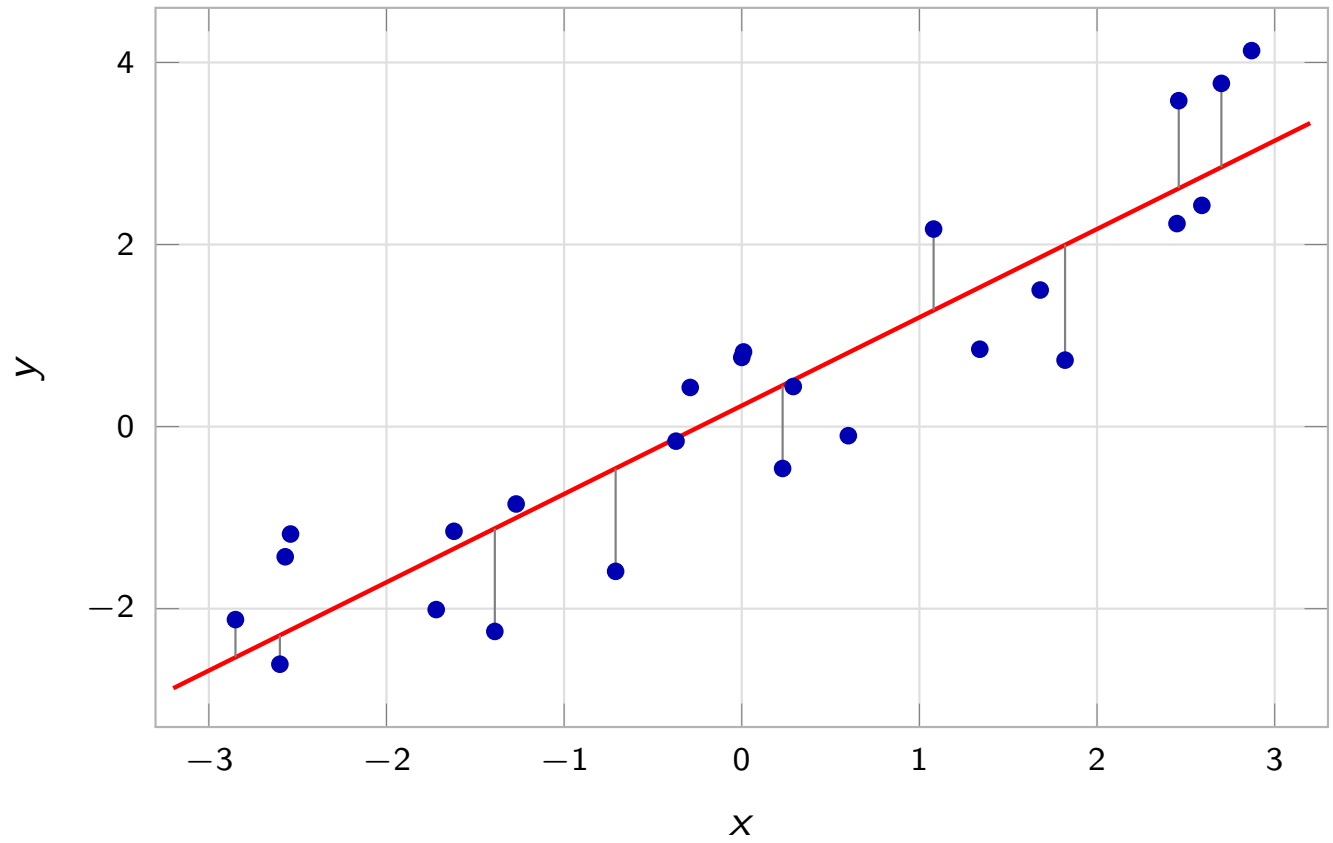
$$\hat{y}_n = \boldsymbol{x}_n^\top \hat{\boldsymbol{\theta}} \quad \text{(valore predetto, } \textit{fitted value}\text{)}$$

$$e_n = y_n - \hat{y}_n \quad \text{(residuo)}$$

In forma vettoriale: $\hat{\boldsymbol{y}} = \boldsymbol{X}\hat{\boldsymbol{\theta}}, \qquad \boldsymbol{e} = \boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{\theta}}.$

- $e_n > 0$: il modello sottostima l'esempio n;
- $e_n < 0$: il modello sovrastima;
- il residuo è la parte di y_n che il modello non spiega;

I residui



- I segmenti verticali grigi sono i residui.
- I minimi quadrati scelgono la retta che minimizza la somma delle loro aree al quadrato.

Esempio

Dati: $(x, y) = (1, 2),\ (2, 3),\ (3, 5)$. Modello con intercetta: $y = \theta_0 + \theta_1 x$.
Ottenere:

- i parametri (calcolando l'inversa)
- l'equazione del modello stimato
- le predizioni
- i residui

Stimare la varianza del rumore

Finora abbiamo supposto σ^2 noto. In realtà possiamo stimarla minimizzando la verosimiglianza logaritmica negativa rispetto a σ^2:

$$\mathcal{L} = \frac{1}{2\sigma^2} \sum_{n=1}^{N} \left(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta}\right)^2 - \sum_{n=1}^{N} \log \frac{1}{\sqrt{2\pi\sigma^2}}$$

$$= \frac{1}{2\sigma^2} \sum_{n=1}^{N} \left(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta}\right)^2 + \frac{N}{2} \log\left(\sigma^2\right) + const$$

Derivando rispetto a σ^2 e annullando:

$$\boxed{\hat{\sigma}^2_{\mathrm{ML}} = \frac{1}{N} \sum_{n=1}^{N} \left(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta}_{\mathrm{ML}}\right)^2}$$

- È la media dei residui al quadrato: l'errore quadratico medio sul training set.

Metriche globali di errore

Nome	**Formula**	**Interpretazione**
MSE	$\frac{1}{N}\sum_n e_n^2$	errore quadratico medio;
RMSE	$\sqrt{\text{MSE}}$	errore tipico
MAE	$\frac{1}{N}\sum_n \lvert e_n \rvert$	errore medio assoluto; meno sensibile agli outlier

Hanno tutti la stessa unità di misura di y.

Metriche globali d'errore

Le metriche calcolate sui dati di addestramento misurano quanto il modello ricorda; quelle sui dati di test misurano quanto generalizza.

- Errore di training basso + errore di test alto $\Rightarrow$ overfitting;
- entrambi alti $\Rightarrow$ underfitting (modello troppo semplice o feature inadatte);
- entrambi bassi e simili $\Rightarrow$ situazione desiderabile.

5. Analisi dei residui

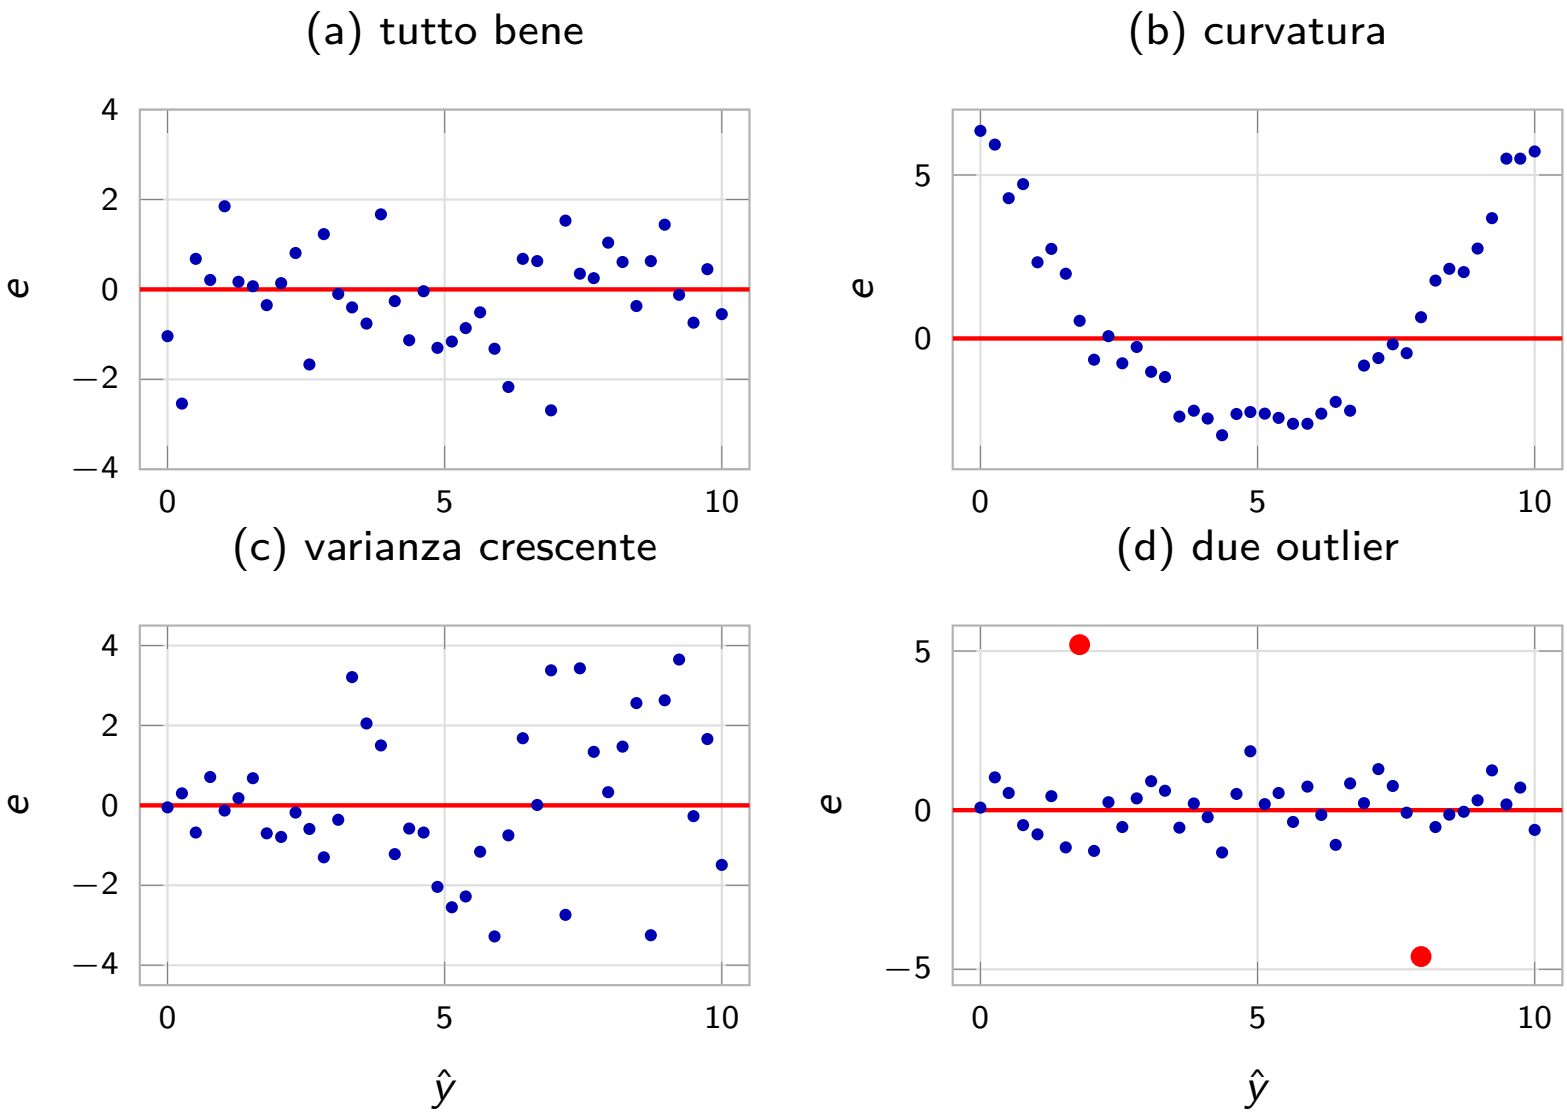
Perché non basta "aver stimato" i parametri

- La formula $\boldsymbol{\theta}_{\mathrm{ML}} = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{y}$ restituisce sempre un risultato, anche se il modello lineare è completamente sbagliato.
- Abbiamo fatto ipotesi precise: relazione lineare, rumore gaussiano, a media zero, con varianza costante e indipendente tra esempi.
- L'analisi dei residui è il modo standard per verificare se queste ipotesi sono compatibili con i dati.

Le quattro ipotesi da verificare

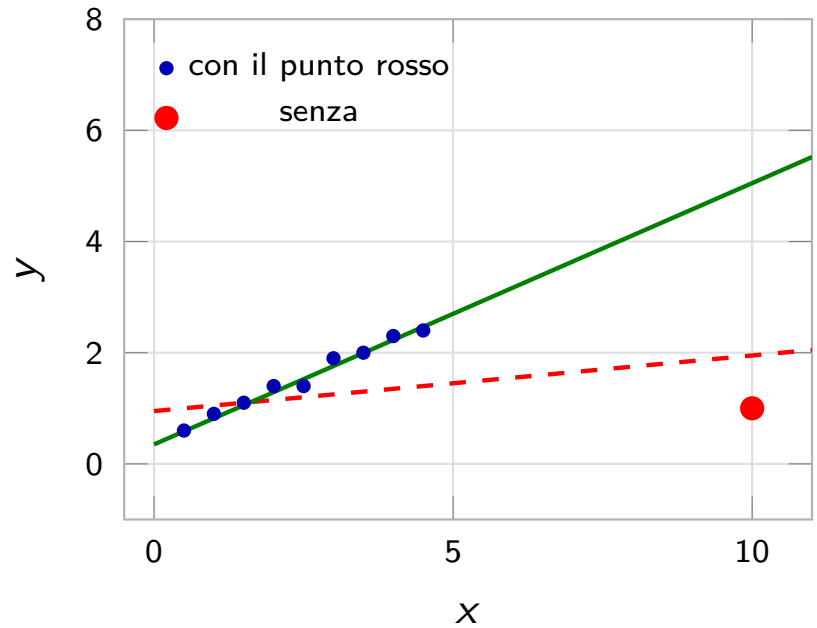
Ipotesi	**In formula**	**Come si verifica**
Linearità	$\boldsymbol{y} = \boldsymbol{x}^\top \boldsymbol{\theta}$	residui vs valori predetti
Omoschedasticità	$\mathrm{Var}[\varepsilon_n] = \sigma^2$ costante	residui vs valori predetti (ampiezza della nuvola)
Indipendenza	ε_n i.i.d.	residui vs indice/tempo; autocorrelazione
Normalità	$\varepsilon_n \sim \mathcal{N}(0, \sigma^2)$	istogramma; *QQ-plot*

Grafico 1: residui vs valori predetti



Outlier

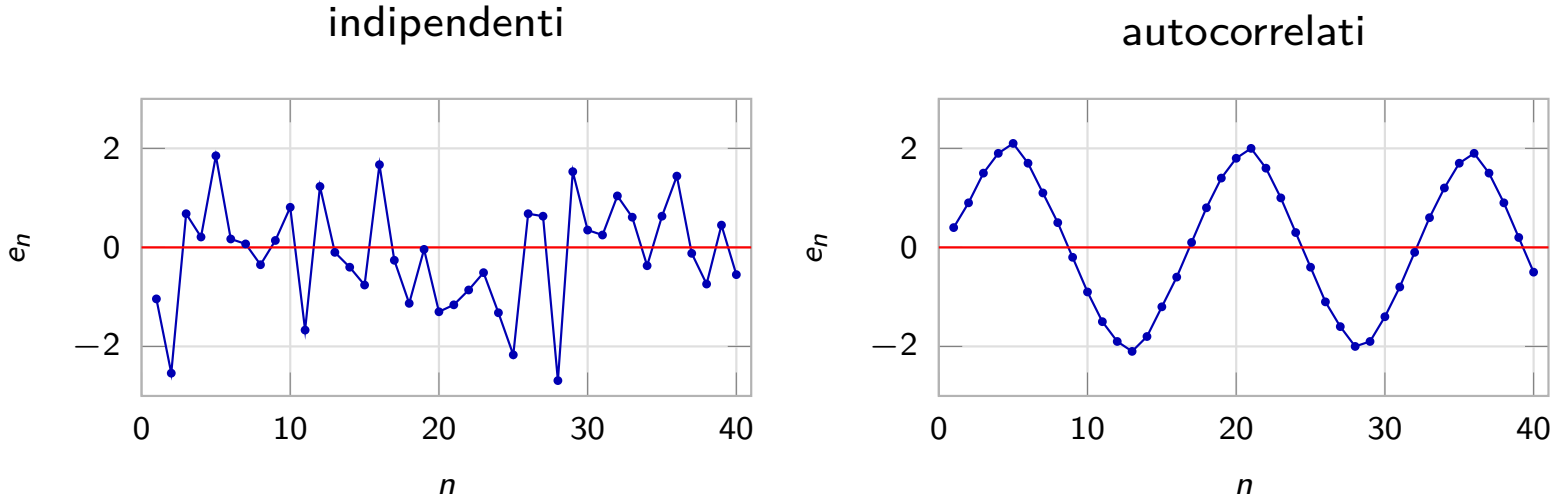
- Outlier: molto lontano dalla nuvola delle altre $\boldsymbol{x}$;
- Punto influente: se lo rimuovo, $\hat{\boldsymbol{\theta}}$ cambia molto.



Il punto rosso ha residuo piccolo rispetto alla retta tratteggiata, ma da solo determina la pendenza del modello: è il caso più pericoloso, perché non si nota guardando solo i residui.

Grafico 2: indipendenza dei residui

- Si disegnano i residui nell'ordine di raccolta dei dati (indice n, tempo, posizione geografica).
- Se i dati sono i.i.d. non deve esserci alcuna struttura: il segno del residuo successivo non deve essere prevedibile da quello corrente.



- A destra i residui restano a lungo positivi e poi a lungo negativi: manca una variabile che varia lentamente nel tempo (es: stagionalità).

QQ-plot (quantile-quantile-plot)

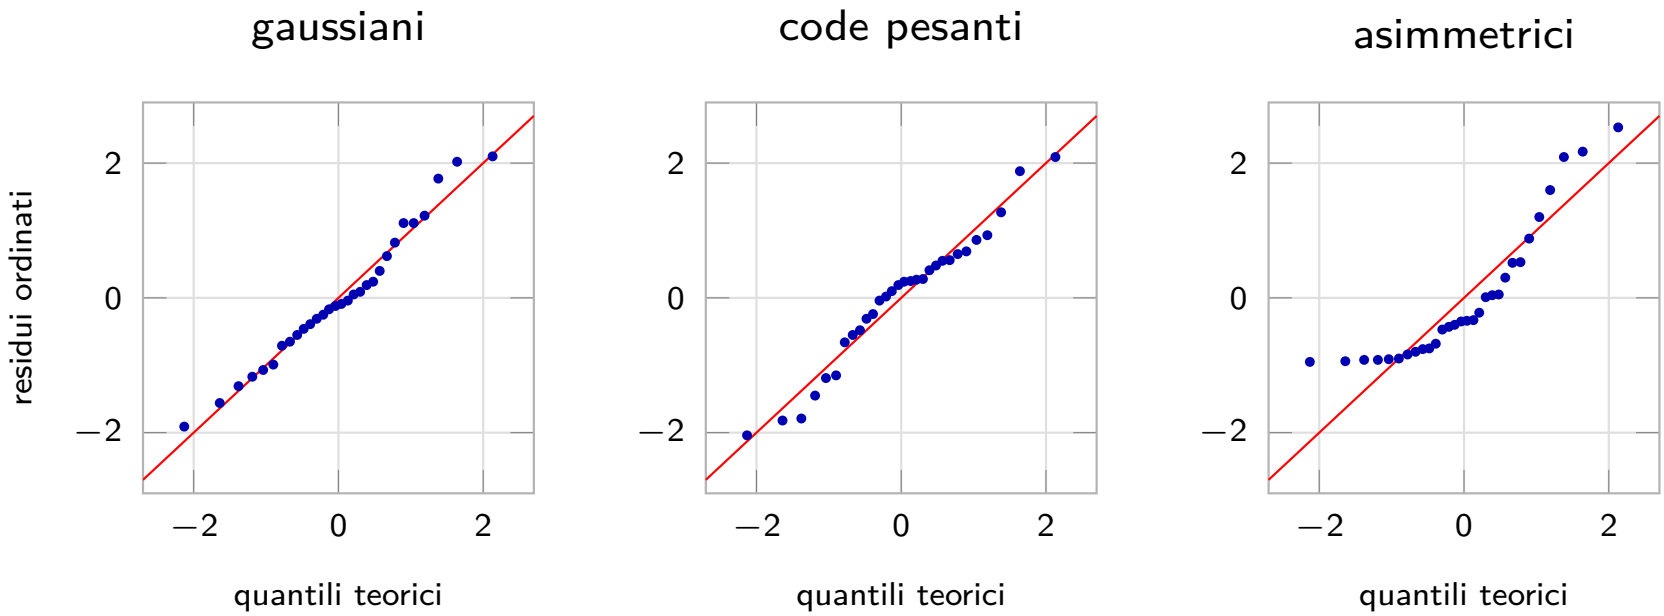
1. Si ordinano i residui: $r_{(1)} \leq r_{(2)} \leq \cdots \leq r_{(N)}$ (e si standardizzano dividendo per $\hat{\sigma}$, ottenendo $e_{(1)} \leq e_{(2)} \leq \cdots \leq e_{(N)}$).
2. Al residuo in posizione i si associa la frazione $p_i = \frac{i-0.5}{N}$ di dati più piccoli di lui.
3. Si calcola il valore z_i che una gaussiana standard "dovrebbe" avere in quella posizione (il suo quantile teorico) [1].
4. Si disegnano le coppie $(z_i,\ e_{(i)})$.

[1] Si può utilizzare la tabella `https://itl.nist.gov/div898/handbook/eda/section3/eda3671.htm?`

QQ-plot esempio

- Residui: $(-0.4, 0.1, -1.2, 0.7, 1.5)$
- $e_{(1)} = -1.44$
- $e_{(2)} = -0.58$
- $e_{(3)} = -0.04$
- $e_{(4)} = 0.60$
- $e_{(5)} = 1.46$
- $z_{(1)} = -1.28$
- $z_{(2)} = -0.52$
- $z_{(3)} = 0$
- $z_{(4)} = 0.52$
- $z_{(5)} = 1.28$

QQ-plot a confronto



Interpretazione

- Punti allineati sulla diagonale $\Rightarrow$ residui compatibili con una gaussiana.
- Curva a S (estremi che si allontanano verso l'alto a destra e verso il basso a sinistra) $\Rightarrow$ code pesanti: più valori estremi del previsto.
- Curva convessa/concava $\Rightarrow$ distribuzione asimmetrica.